

2025春

智能信号处理导论

实验I：线性回归

Introduction to **I**ntelligent **S**ignal **P**rocessing

Part II: Fundamentals of Machine Learning



李 杨

电子工程系，新技术楼705

86418051-7051, li.yang@hit.edu.cn

<http://homepage.hit.edu.cn/liyang>



2.2.4 Example: Linear Regression


- **线性回归**：我们的目标是建立一个系统，将向量 $x \in \mathbb{R}^n$ 作为输入，预测标量 $y \in \mathbb{R}$ 作为输出。线性回归的输出是其输入的线性函数。令 \hat{y} 表示模型预测 y 应该取的值。我们定义输出为

$$\hat{y} = \omega^T x$$

$\omega \in \mathbb{R}^n$ ：参数向量（决定每个预测如何影响预测的权重）

- **定义任务 T** ：通过输出 $\hat{y} = \omega^T x$ 从 x 预测 y 。

——Tracking





Performance Measure, P

■ **测试集 (test set)** : 不用来训练模型，而是评估模型性能如何

➤ 将输入的设计矩阵记作 $\mathbf{x}^{(\text{test})}$ 回归目标向量记作 $\mathbf{y}^{(\text{test})}$

➤ 假设我们有 m 个输入样本组成的设计矩阵。

➤ 每个样本对应的正确值 y 组成的**回归目标向量**。


样本1:	特征1	特征2	特征3	特征K
样本2:	特征1	特征2	特征3	特征K
.....
样本M*N:	特征1	特征2	特征3	特征K

➤ **均方误差 (mean squared error)** : 一种度量方法

若 $\hat{\mathbf{y}}^{(\text{test})}$ 表示模型在测试集上的预测值，则

$$\text{MSE}_{\text{test}} = \frac{1}{m} \sum_i (\hat{\mathbf{y}}^{(\text{test})} - \mathbf{y}^{(\text{test})})_i^2.$$

当 $\hat{\mathbf{y}}^{(\text{test})} = \mathbf{y}^{(\text{test})}$ 时，误差为0.



➤ **欧氏距离**

$$\text{MSE}_{\text{test}} = \frac{1}{m} \left\| \hat{\mathbf{y}}^{(\text{test})} - \mathbf{y}^{(\text{test})} \right\|_2^2$$

p 范数 $\| \mathbf{x} \|_p = \left(\sum_i |x_i|^p \right)^{\frac{1}{p}}$

补充：赋范线性空间

➤ 赋范线性空间(normed linear space)是在线性空间中引进一种与代数运算相联系的度量，即由向量范数诱导出的度量。赋范线性空间称为Banach空间，是指由范数导出的度量是完备的。

➤ 定义：设 X 是线性空间，如果 X 中每一个元素 x 都有一个实数 $\|x\|$ 与之对应，且满足：

(1) $\|x\|=0$ 当且仅当 $x=0$ ；

(2) 对任何 $x \in X$ 及 $\alpha \in \mathbb{C}$ （实数或复数）， $\|\alpha x\| = |\alpha| \|x\|$ ；

(3) 对任意 $x, y \in X$ ， $\|x+y\| \leq \|x\| + \|y\|$ 。

则称 X 为赋范线性空间，称 $\|x\|$ 为元素的范数。

$$p\text{范数} \|x\|_p = \left(\sum_i |x_i|^p \right)^{\frac{1}{p}}$$

可定义元素 x 和 y 的距离： $\rho(x, y) = \|x - y\|$ ($x, y \in X$)



Experience, E

$$p\text{范数 } \|x\|_p = \left(\sum_i |x_i|^p \right)^{\frac{1}{p}}$$

■ 构建ML算法:

$$\text{MSE}_{\text{test}} = \frac{1}{m} \left\| \hat{\mathbf{y}}^{(\text{test})} - \mathbf{y}^{(\text{test})} \right\|_2^2$$

$$\hat{\mathbf{y}} = \boldsymbol{\omega}^T \mathbf{x}$$

✓ 设计算法，通过观察训练集获得经验，减少 MSE_{test} ，以改进权重 $\boldsymbol{\omega}$

✓ 通过最小化训练集上的均方误差 $\text{MSE}_{\text{train}}$

✓ 求导

$$\nabla_{\boldsymbol{\omega}} \text{MSE}_{\text{train}} = 0$$

$$\Rightarrow \nabla_{\boldsymbol{\omega}} \frac{1}{m} \left\| \hat{\mathbf{y}}^{(\text{train})} - \mathbf{y}^{(\text{train})} \right\|_2^2 = 0 \quad \because \text{MSE}_{\text{test}} = \frac{1}{m} \left\| \hat{\mathbf{y}}^{(\text{test})} - \mathbf{y}^{(\text{test})} \right\|_2^2$$

$$\Rightarrow \frac{1}{m} \nabla_{\boldsymbol{\omega}} \left\| \mathbf{X}^{(\text{train})} \boldsymbol{\omega} - \mathbf{y}^{(\text{train})} \right\|_2^2 = 0 \quad \because \hat{\mathbf{y}} = \boldsymbol{\omega}^T \mathbf{x}$$

$$\Rightarrow \nabla_{\boldsymbol{\omega}} \left(\mathbf{X}^{(\text{train})} \boldsymbol{\omega} - \mathbf{y}^{(\text{train})} \right)^T \left(\mathbf{X}^{(\text{train})} \boldsymbol{\omega} - \mathbf{y}^{(\text{train})} \right) = 0$$

$$\Rightarrow \nabla_{\boldsymbol{\omega}} \left(\underline{\mathbf{w}^T \mathbf{X}^{(\text{train})T} \mathbf{X}^{(\text{train})} \mathbf{w}} - \underline{2 \mathbf{w}^T \mathbf{X}^{(\text{train})T} \mathbf{y}^{(\text{train})}} + \mathbf{y}^{(\text{train})T} \mathbf{y}^{(\text{train})} \right) = 0$$

$$\Rightarrow 2 \mathbf{X}^{(\text{train})T} \mathbf{X}^{(\text{train})} \mathbf{w} - 2 \mathbf{X}^{(\text{train})T} \mathbf{y}^{(\text{train})} = 0$$

$$\Rightarrow \mathbf{w} = \left(\mathbf{X}^{(\text{train})T} \mathbf{X}^{(\text{train})} \right)^{-1} \mathbf{X}^{(\text{train})T} \mathbf{y}^{(\text{train})}$$

——正规方程 (Normal Equation)

2.2 Learning Algorithms

2.2.4 Example: Linear Regression

Experience, E

$$p\text{范数} \|x\|_p = \left(\sum_i |x_i|^p \right)^{\frac{1}{p}}$$

$$\Rightarrow w = \left(X^{(\text{train})\top} X^{(\text{train})} \right)^{-1} X^{(\text{train})\top} y^{(\text{train})}$$



评价
使用测试集



$$\text{MSE}_{\text{test}} = \frac{1}{m} \sum_i (\hat{y}^{(\text{test})} - y^{(\text{test})})_i^2.$$

$$\Rightarrow w = \left(X^{(\text{train})\top} X^{(\text{train})} \right)^{-1} X^{(\text{train})\top} y^{(\text{train})}$$



Example of the Linear Regression Learning Algorithm

- 训练集包括十个数据点，每点包含一个特征，只有一个要学习的参数 w_1 。
- (左) 观察到线性回归学习 w_1 ，使直线 $y=w_1x$ 尽量接近穿过所有的训练点。
- (右) 标注点表示由学习到的 w_1 的值，它可以最小化训练集上的均方误差。

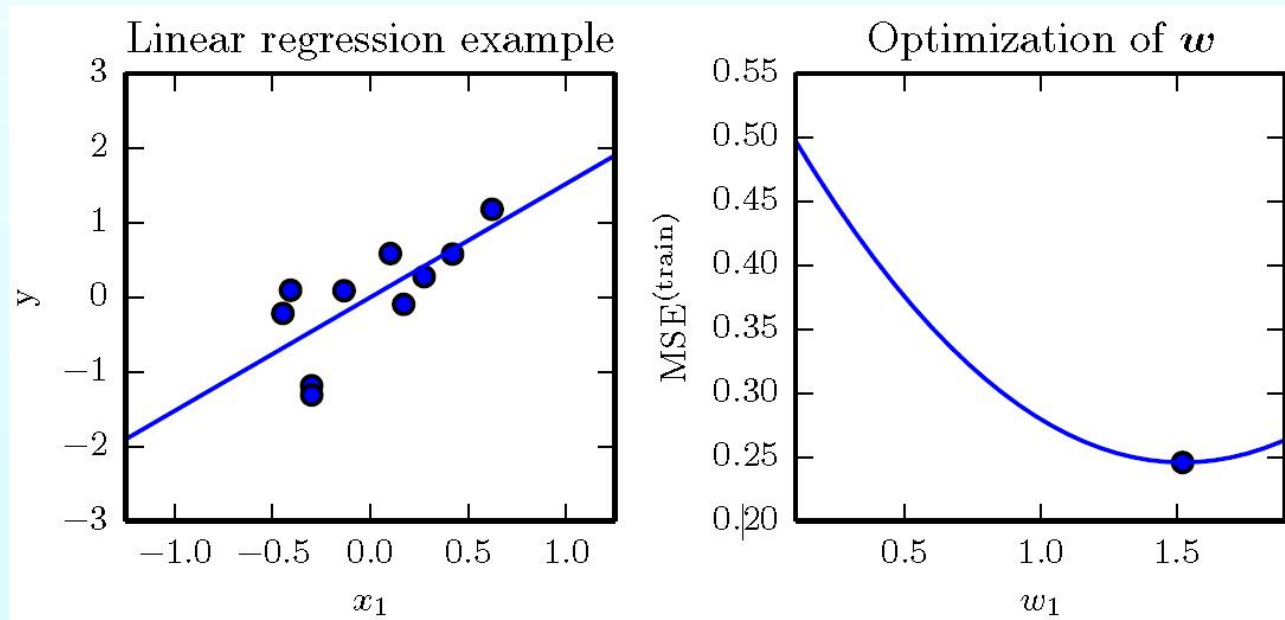




2.2.4 Example: Linear Regression

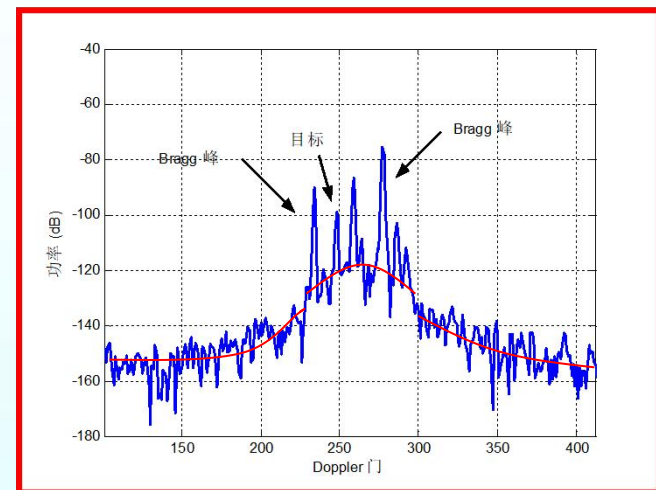
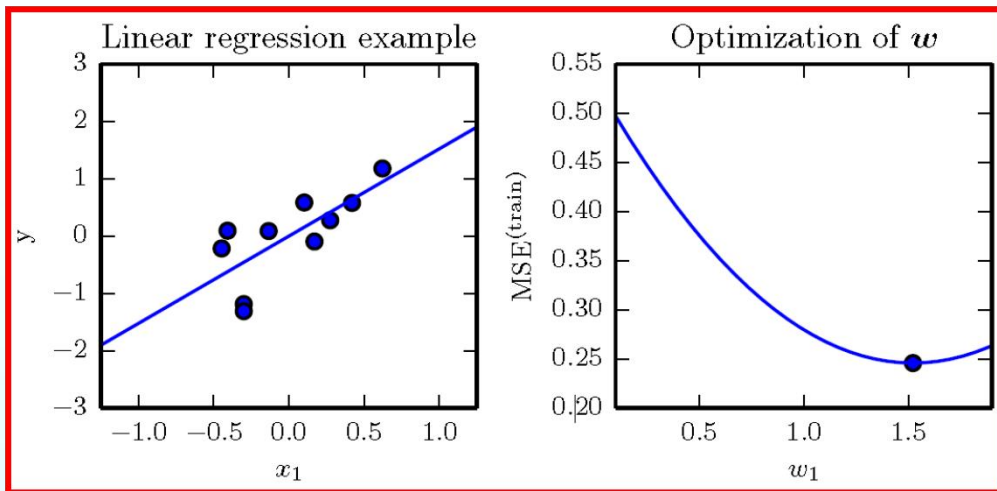
□ Lab 1: How to Design a Simulation like that?

- ✓ List all Steps of the Procedure
- ✓ Plot the Flow Chart



2.2.4 Example: Linear Regression

➤ Lab 1-1: How to Design a Simulation like that?



- ✓ Step1: 看懂问题是什么
- ✓ Step2: 弄清数据来源
- ✓ Step3: 明确处理过程和算法
- ✓ Step4: 注意评价和分析




2.2.4 Example: Linear Regression

□ Discussion

➤ How to Design a Simulation like that?

✓ List all Steps of the Procedure

✓ Plot the Flow Chart



- ✓ Step1: 看懂问题是什么
- ✓ Step2: 弄清数据来源
- ✓ Step3: 明确处理过程和算法
- ✓ Step4: 注意评价和分析



2.2.4 Example: Linear Regression

Lab 1-1


➤ **Try It (Linear Regression) in Lab 1 with
Matlab® on ~**

2.3 The Basic Principles of ML Algorithm Design

2.3.1 容量、过拟合、欠拟合




Underfitting




x_0 线性函数

Appropriate capacity



x_0 二次函数

Overfitting




x_0 9阶的多项式

- 用三个模型拟合了这个训练集的样本。训练数据通过**随机抽取 x** 然后用**二次函数确定性地生成 y** 来合成的。（前提：无噪声）
- （左）线性函数拟合数据——欠拟合——无法捕捉数据中的曲率信息。
- （中）用二次函数拟合数据不会导致明显的欠拟合或者过拟合。
- （右）9阶的多项式拟合数据会导致过拟合。解此欠定的正规方程。得出的解能够精确地穿过所有的训练点——**无法提取有效的结构信息**。¹²

2.3 The Basic Principles of ML Algorithm Design

2.3.1 容量、过拟合、欠拟合



■ 改变模型容量——改变输入特征数——不是越多越好

- ✓ 容量不足的模型不能解决复杂任务。
- ✓ 容量高的模型能够解决复杂的任务，但是当其容量高于任务所需时，有可能会过拟合。

□ So far we have only described changing a model's capacity by changing the number of input features it has (and simultaneously adding new parameters associated with those features).



Ref. 2.3.4.3 Cross-Validation

Define $\text{KFoldXV}(\mathbb{D}, A, L, k)$:

Require: \mathbb{D} 为给定数据集，其中元素为 $z^{(i)}$

Require: A 为学习算法，可视为一个函数（使用数据集作为输入，输出一个学好的函数）

Require: L 为损失函数，可视为来自学好的函数 f ，将样本 $z^{(i)} \in \mathbb{D}$ 映射到 \mathbb{R} 中标量的函数

Require: k 为折数

将 \mathbb{D} 分为 k 个互斥子集 \mathbb{D}_i ，它们的并集为 \mathbb{D}

for i from 1 to k **do**

$f_i = A(\mathbb{D} \setminus \mathbb{D}_i)$

for $z^{(j)}$ in \mathbb{D}_i **do**

$e_j = L(f_i, z^{(j)})$

end for



end for

Return e

Lab 1-2

□ Try to Write up Pseudo-code for the *Linear Regression Example*

□ Not limited to the data and form of the function





Lab 1-2-Ref

Eg. of the Linear Regression Learning

$$\Rightarrow w = \left(X^{(\text{train})\top} X^{(\text{train})} \right)^{-1} X^{(\text{train})\top} y^{(\text{train})}$$

- 训练集包括十个数据点，每点包含一个特征，只有一个要学习的参数 w_1 。
- (左) 观察到线性回归学习 w_1 ，使直线 $y=w_1x$ 尽量接近穿过所有的训练点。
- (右) 标注点表示由学习到的 w_1 的值，它可以最小化训练集上的均方误差。





End of Part II